

电信客户流失数据分析及可视化调研报告

1. 引言

在电信行业竞争日益激烈的背景下，客户流失管理已成为企业运营的核心关注点。获取新客户的成本远高于维系现有客户，因此理解和预测客户流失行为对于制定有效的客户保留策略至关重要。本报告基于Kaggle平台公开的电信客户流失数据集，通过数据清洗、探索性分析、可视化展示和机器学习建模，系统性地分析客户流失的关键因素，并为业务决策提供数据支持。

2. 数据集与分析方法概述

本分析采用的数据集为WA_Fn-UseC_-Telco-Customer-Churn.csv，共包含7043条客户记录。数据集涵盖了客户的人口统计特征、账户信息、服务使用情况以及是否流失的标签。分析工具使用Python编程语言，核心依赖库包括Pandas和NumPy用于数据处理、Matplotlib和Seaborn用于数据可视化、Scikit-learn用于机器学习建模。

分析流程分为六个步骤：数据加载、数据清洗、描述性统计、可视化分析、机器学习预测和特征重要性评估。整个流程从原始数据出发，经过清洗和编码后，既通过可视化图表呈现数据特征，也通过随机森林模型进行流失预测和特征重要性排序。

3. 数据清洗与预处理

原始数据加载后包含7043行记录和21个字段。数据清洗阶段主要处理两个问题。第一，TotalCharges字段被转换为数值类型，其中无法转换的值被设为缺失值并随后删除，这一操作确保了后续数值计算的准确性。第二，Churn字段从Yes/No文本标签转换为二值数值，其中Yes映射为1表示流失，No映射为0表示未流失。

清洗完成后，剩余客户记录为7032行，说明有11条记录因TotalCharges数据异常被移除。清洗后数据显示，流失客户共计1869人，整体流失率为26.58%。这一流失率水平为后续分析和建模提供了明确的预测目标。

4. 描述性统计特征

对数值型字段进行描述性统计分析，关键特征包括tenure（在网时长）、MonthlyCharges（月费）和TotalCharges（总费用）。tenure字段显示客户在网时长分布范围从0到72个月，平均在网时长约为32个月。MonthlyCharges从18.25美元到118.75美元不等，平均月费约为64.76美元。TotalCharges作为累计消费金额，取值范围从18.8美元到8684.5美元。

这些统计指标反映出客户群体在消费水平和在网时长上存在较大差异，为后续探究这些特征与流失的关系奠定了基础。

5. 可视化分析



本分析生成了六张核心可视化图表，分别从不同角度展示流失情况。

第一张图表为整体流失率饼图，直观显示流失客户占26.6%，未流失客户占73.4%，清晰呈现了数据集中正负样本的比例关系。

第二张图表展示合同类型与流失的关系。从柱状图可以看出，按月签约（Month-to-month）的客户流失数量明显高于一年期和两年期合同的客户，这提示短期合同客户具有更高的流失风险。

第三张图表展示在线安全服务与流失的关系。没有购买在线安全服务的客户中流失比例显著高于购买了该服务的客户，表明增值服务对客户留存具有积极作用。

第四张图表为月费箱线图对比。流失客户的月费中位数明显高于未流失客户，且流失客户的月费分布更为分散，说明较高的月费可能是促使客户流失的因素之一。

第五张图表为在网时长箱线图对比。未流失客户的中位在网时长远高于流失客户，流失客户的在网时长普遍较短，多数集中在20个月以内，说明新客户更容易流失。

第六张图表展示伴侣状态与流失的关系。没有伴侣的客户流失比例略高于有伴侣的客户，表明家庭支持因素可能对客户稳定性有一定影响。

6. 机器学习预测建模

为构建流失预测模型，首先对所有分类变量进行标签编码，将文本类别转换为数值。随后将customerID作为标识列剔除，Churn作为目标变量，其余字段作为特征。数据集按70%和30%的比例划分为训练集和测试集，随机种子设为42以保证结果可复现。

采用随机森林分类器进行建模，树的数量设为100棵，其余参数使用默认值。在测试集上的评估结果显示，模型准确率达到79.49%。分类报告进一步显示，对于未流失客户的召回率较高，但对于流失客户的精确率和召回率相对较低，说明模型在识别流失客户方面仍有提升空间。这可能与数据集中流失样本相对较少有关，也提示需要进一步优化模型或采用采样技术处理类别不平衡问题。

7. 特征重要性分析

随机森林模型提供了特征重要性分数，用于评估每个特征对预测流失的贡献程度。特征重要性排序结果显示，tenure（在网时长）是最重要的预测因子，其重要性分数远高于其他特征。其次是MonthlyCharges（月费）和TotalCharges（总费用），这两项消费相关特征也占据了重要位置。

在分类特征中，Contract（合同类型）和OnlineSecurity（在线安全）的重要性较为突出，这与可视化分析中观察到的模式一致。特征重要性排序从定量角度验证了合同类型、服务附加项和消费水平是影响客户流失的核心因素。

8. 结论与业务启示

基于上述分析，可以得出以下核心结论。整体来看，电信客户流失率为26.58%，这一比例处于较高水平，需要引起业务重视。在网时长是最关键的流失预测指标，新客户尤其需要重点关注和关怀。合同类型是第二重要的预测因子，月度合同客户的流失风险远高于长期合同客户，推广长期合同是降低流失率的有效手段。月费较高的客户更倾向于流失，这提示需要关注高价值客户的满意度和感知价值。未购买在线安全等增值服务的客户流失概率更高，说明增值服务不仅带来收入，还能增强客户粘性。

针对这些发现，建议采取以下策略：针对新客户设计专属留存计划，例如前三个月提供额外的客户支持和定期回访；推广年度或两年期合同，通过折扣优惠吸引客户延长合同期限；审视高月费客户的套餐合理性，提供个性化优惠或升级方案以避免因价格因素流失；在销售和服务环节突出在线安全等技术支持的附加价值，提升客户对服务的依赖度。

本分析通过数据驱动的方式识别了流失的关键驱动因素，为电信运营商的客户挽留策略提供了明确的数据支撑和行动方向。后续工作可以考虑引入更多算法如XGBoost、LightGBM进行对比，或者采用过采样技术处理类别不平衡问题以进一步提升模型的预测性能。